



Algoritmos Heurísticos en Optimización Combinatoria

Rafael Martí Cunqueiro

Departament d'Estadística i Investigació Operativa

VNIVERSITAT [òv] Facultat de Ciències Matemàtiques
ID VALÈNCIA

Programa

1. Introducción
2. Calidad de los Algoritmos
3. El Problema del Viajante
4. Métodos Constructivos
 - 4.1. Heurísticos del Vecino más Próximo
 - 4.2. Heurísticos de Inserción
 - 4.3. Heurísticos basados en Árboles Generadores
 - 4.4. Heurísticos basados en Ahorros
5. Métodos de Búsqueda Local
 - 5.1. Procedimientos de 2-intercambio
 - 5.2. Procedimientos de k -intercambio
 - 5.3. Algoritmo de Lin y Kernighan
6. Métodos Combinados
 - 6.1. Procedimientos Aleatorizados
 - 6.2. Métodos Multi-Arranque
 - 6.3. GRASP
7. Búsqueda Tabu
 - 7.1. Principios del Procedimiento
 - 7.2. Uso de Memoria
 - 7.3. Estrategias y Atributos
 - 7.4. Mejoras y Especializaciones
8. Templado Simulado
 - 8.1. El Modelo Físico
 - 8.2. El Modelo de Optimización
 - 8.3. Parámetros y Mejoras
9. Métodos Evolutivos
 - 9.1. Algoritmos Genéticos
 - 9.2. Scatter Search
 - 9.3. Re-encadenamiento de trayectorias
10. Nuevos Métodos
 - 10.1. Algoritmo Meméticos
 - 10.2. Colonias de Hormigas
 - 10.3. Métodos de Entorno Variable

1. Introducción

Los métodos descritos en este libro reciben el nombre de algoritmos heurísticos, metaheurísticos o sencillamente heurísticos. Este término deriva de la palabra griega *heuriskein* que significa encontrar o descubrir y se usa en el ámbito de la optimización para describir una clase de algoritmos de resolución de problemas.

En el lenguaje coloquial, optimizar significa poco más que mejorar; sin embargo, en el contexto científico la optimización es el proceso de tratar de encontrar la mejor solución posible para un determinado problema. En un *problema de optimización* existen diferentes soluciones, un criterio para discriminar entre ellas y el objetivo es encontrar la mejor. De forma más precisa, estos problemas se pueden expresar como encontrar el valor de unas *variables de decisión* para los que una determinada *función objetivo* alcanza su valor máximo o mínimo. El valor de las variables en ocasiones está sujeto a unas *restricciones*.

Podemos encontrar una gran cantidad de problemas de optimización, tanto en la industria como en la ciencia. Desde los clásicos problemas de diseño de redes de telecomunicación u organización de la producción hasta los más actuales en ingeniería y re-ingeniería de software, existe una infinidad de problemas teóricos y prácticos que involucran a la optimización.

Algunas clases de problemas de optimización son relativamente fáciles de resolver. Este es el caso, por ejemplo, de los *problemas lineales*, en los que tanto la función objetivo como las restricciones son expresiones lineales. Estos problemas pueden ser resueltos con el conocido método Simplex; sin embargo, muchos otros tipos de problemas de optimización son muy difíciles de resolver. De hecho, la mayor parte de los que podemos encontrar en la práctica entran dentro de esta categoría.

La idea intuitiva de problema “difícil de resolver” queda reflejada en el término científico NP-hard utilizado en el contexto de la complejidad algorítmica. En términos coloquiales podemos decir que un problema de optimización difícil es aquel para el que no podemos garantizar el encontrar la mejor solución posible en un tiempo razonable. La existencia de una gran cantidad y variedad de problemas difíciles, que aparecen en la práctica y que necesitan ser resueltos de forma eficiente, impulsó el desarrollo de procedimientos eficientes para encontrar buenas soluciones aunque no fueran óptimas. Estos métodos, en los que la rapidez del proceso es tan importante como la calidad de la solución obtenida, se denominan heurísticos o aproximados. En Díaz y otros (1996) se recogen hasta ocho definiciones diferentes de algoritmo heurístico, entre las que destacamos la siguiente:

“Un método heurístico es un procedimiento para resolver un problema de optimización bien definido mediante una aproximación intuitiva, en la que la estructura del problema se utiliza de forma inteligente para obtener una buena solución.”

En contraposición a los *métodos exactos* que proporcionan una solución óptima del problema, los *métodos heurísticos* se limitan a proporcionar una buena solución del problema no necesariamente óptima. Lógicamente, el tiempo invertido por un método exacto para encontrar la solución óptima de un problema difícil, si es que existe tal método, es de un orden de magnitud muy superior al del heurístico (pudiendo llegar a ser tan grande en muchos casos, que sea inaplicable).

En este texto consideraremos los llamados problemas de *Optimización Combinatoria*. En estos problemas el objetivo es encontrar el máximo (o el mínimo) de una determinada función sobre un conjunto finito de soluciones que denotaremos por S . No se exige ninguna condición o propiedad sobre la función objetivo o la definición del conjunto S . Es importante notar que dada la finitud de S , las variables han de ser discretas, restringiendo su dominio a una serie finita de valores. Habitualmente, el número de elementos de S es muy elevado, haciendo impracticable la evaluación de todas sus soluciones para determinar el óptimo.

En los últimos años ha habido un crecimiento espectacular en el desarrollo de procedimientos heurísticos para resolver problemas de optimización. Este hecho queda claramente reflejado en el gran número de artículos en publicados en revistas especializadas. En 1995 se edita el primer número de la revista *Journal of Heuristics* dedicada íntegramente a la difusión de los procedimientos heurísticos.

Aunque hemos mencionado el caso de la resolución de un problema difícil, existen otras razones para utilizar métodos heurísticos, entre las que podemos destacar:

- El problema es de una naturaleza tal que no se conoce ningún método exacto para su resolución.
- Aunque existe un método exacto para resolver el problema, su uso es computacionalmente muy costoso.
- El método heurístico es más flexible que un método exacto, permitiendo, por ejemplo, la incorporación de condiciones de difícil modelización.
- El método heurístico se utiliza como parte de un procedimiento global que garantiza el óptimo de un problema. Existen dos posibilidades:
 - El método heurístico proporciona una buena solución inicial de partida.
 - El método heurístico participa en un paso intermedio del procedimiento, como por ejemplo las reglas de selección de la variable a entrar en la base en el método Simplex.

Al abordar el estudio de los algoritmos heurísticos podemos comprobar que dependen en gran medida del problema concreto para el que se han diseñado. En otros métodos de resolución de propósito general, como pueden ser los algoritmos exactos de Ramificación y Acotación, existe un procedimiento conciso y preestablecido, independiente en gran medida del problema abordado. En los métodos heurísticos esto no es así. Las técnicas e ideas aplicadas a la resolución de un problema son específicas de éste y aunque, en general, pueden ser trasladadas a otros problemas, han de particularizarse en cada caso. Así pues, es necesario referirse a un problema concreto para estudiar con detalle los procedimientos heurísticos.

En los capítulos segundo y tercero se describen los métodos heurísticos. Hemos seleccionado el Problema del Viajante para describir estos métodos por cumplir una serie de propiedades que lo hacen especialmente indicado. Dicho problema puede enunciarse del siguiente modo:

“Un viajante de comercio ha de visitar n ciudades, comenzando y finalizando en su propia ciudad. Conociendo el coste de ir de cada ciudad a otra, determinar el recorrido de coste mínimo.”

En la siguiente sección introducimos algunos otros problemas combinatorios que también nos ayudaran a explicar e ilustrar algunas de las técnicas así como a plantear ejercicios para el estudiante. Podemos citar las siguientes razones por las que el problema del viajante ha recibido una especial atención.

- Resulta muy intuitivo y con un enunciado muy fácil de comprender.
- Es extremadamente difícil de resolver por lo que resulta un desafío constante para los investigadores del área.
- Es uno de los que mas interés ha suscitado en Optimización Combinatoria y sobre el que se ha publicado abundante material.
- Sus soluciones admiten una doble interpretación: mediante grafos y mediante permutaciones, dos herramientas de representación muy habituales en problemas combinatorios, por lo que las ideas y estrategias empleadas son, en gran medida, generalizables a otros problemas.
- La gran mayoría de las técnicas que han ido apareciendo en el área de la Optimización Combinatoria han sido probadas en él, puesto que su resolución es de gran complejidad.

Existen muchos métodos heurísticos de naturaleza muy diferente, por lo que es complicado dar una clasificación completa. Además, muchos de ellos han sido diseñados para un problema específico sin posibilidad de generalización o aplicación a otros problemas similares. El siguiente esquema trata de dar unas categorías amplias, no excluyentes, en donde ubicar a los heurísticos mas conocidos:

Métodos de Descomposición

El problema original se descompone en subproblemas mas sencillos de resolver, teniendo en cuenta, aunque sea de manera general, que ambos pertenecen al mismo problema.

Métodos Inductivos

La idea de estos métodos es generalizar de versiones pequeñas o más sencillas al caso completo. Propiedades o técnicas identificadas en estos casos más fáciles de analizar pueden ser aplicadas al problema completo.

Métodos de Reducción

Consiste en identificar propiedades que se cumplen mayoritariamente por las buenas soluciones e introducirlas como restricciones del problema. El objeto es restringir el espacio de soluciones simplificando el problema. El riesgo obvio es dejar fuera las soluciones óptimas del problema original.

Métodos Constructivos

Consisten en construir literalmente paso a paso una solución del problema. Usualmente son métodos deterministas y suelen estar basados en la mejor elección en cada iteración. Estos métodos han sido muy utilizados en problemas clásicos como el del viajante.

Métodos de Búsqueda Local

A diferencia de los métodos anteriores, los procedimientos de *búsqueda o mejora local* comienzan con una solución del problema y la mejoran progresivamente. El procedimiento realiza en cada paso un *movimiento* de una solución a otra con mejor valor. El método finaliza cuando, para una solución, no existe ninguna solución accesible que la mejore.

Si bien todos estos métodos han contribuido a ampliar nuestro conocimiento para la resolución de problemas reales, los métodos constructivos y los de búsqueda local constituyen la base de los procedimientos metaheurísticos. Por ello, estudiaremos en el capítulo segundo los métodos constructivos en el problema del viajante y en el capítulo tercero los métodos de búsqueda local en este mismo problema. El lector podrá encontrar alusiones a lo largo del texto a cualquiera de los métodos de descomposición, inductivos o de reducción, pero no dedicaremos una sección específica a su estudio. Alternativamente, prestaremos especial atención a los métodos resultantes de combinar la *construcción* con la *búsqueda local* y sus diferentes variantes en el capítulo tercero, puesto que puede considerarse un punto de inicio en el desarrollo de método metaheurísticos.

En los últimos años han aparecido una serie de métodos bajo el nombre de *Metaheurísticos* con el propósito de obtener mejores resultados que los alcanzados por los heurísticos tradicionales. El término metaheurístico fue introducido por Fred Glover en 1986. En este libro utilizaremos la acepción de heurísticos para referirnos a los métodos clásicos en contraposición a la de metaheurísticos que reservamos para los más recientes y complejos. En algunos textos podemos encontrar la expresión “heurísticos modernos” refiriéndose a los meta-heurísticos (Reeves, 1995) tal y como se menciona: “*The modern-coin comes from ... the way they attempt to simulate some naturally-occurring process.*”.. Los profesores Osman y Kelly (1995) introducen la siguiente definición:

“Los procedimientos Metaheurísticos son una clase de métodos aproximados que están diseñados para resolver problemas difíciles de optimización combinatoria, en los que los heurísticos clásicos no son efectivos. Los Metaheurísticos proporcionan un marco general para crear nuevos algoritmos híbridos combinando diferentes conceptos derivados de la inteligencia artificial, la evolución biológica y los mecanismos estadísticos”

Los procedimientos Meta-Heurísticos se sitúan conceptualmente “por encima” de los heurísticos en el sentido que guían el diseño de éstos. Así, al enfrentarnos a un problema de optimización, podemos escoger cualquiera de estos métodos para diseñar un algoritmo específico que lo resuelva aproximadamente. En Glover (1986) se introduce dicha idea según:

“A metaheuristic refers to a master strategy that guides and modifies other heuristics to produce solutions beyond those that are normally generated in a quest for local optimality. The heuristics guided by such a meta-strategy may be high level procedures or may embody nothing more than a description of available moves for transforming one solution into another, together with an associated evaluation rule”.

Otras definiciones más recientes son:

“An iterative master process that guides and modifies the operations of subordinate heuristics to efficiently produce high-quality solutions. It may manipulate a complete (or incomplete) single solution or a collection of solutions at each iteration. The subordinate heuristics may be high (or low) level procedures, or a simple local search, or just a construction method.” Voß et al (1997)

“It is a heuristic framework which combines a non-problem-specific control procedure with a subordinate heuristic in order to commonly find better solutions than the latter one would be able on its own. The control process mentioned can be implemented for different problems without changing its ingredients significantly.” Greistorfer (2000)

En estos momentos existe un gran desarrollo y crecimiento de estos métodos. En este libro vamos a limitarnos a aquellos procedimientos relativamente consolidados y que han probado su eficacia sobre una colección significativa de problemas. Específicamente consideraremos en el capítulo quinto la Búsqueda Tabú, en el sexto el Templado Simulado y en el séptimo los diferentes Métodos Evolutivos, incluyendo los Algoritmos Genéticos y la Búsqueda Dispersa (Scatter Search). Los métodos GRASP junto con los Multi-Arranque han sido incluidos en el capítulo cuarto de Métodos Combinados que sirve de “puente” entre los métodos heurísticos y los metaheurísticos.

Es importante notar que para la correcta comprensión y asimilación de los métodos descritos, resulta indispensable su puesta en práctica, para lo cual el lector deberá programar en un ordenador los algoritmos descritos y resolver algún problema de optimización combinatoria. Recomendamos utilizar algún lenguaje de programación de relativo bajo nivel como el C que permita controlar los detalles de implementación. La siguiente sección incluye una colección de problemas de entre los que el lector puede escoger alguno e ir trabajando con él, aplicando los métodos descritos a lo largo de todo el texto.

Al resolver un problema de forma heurística debemos de medir la calidad de los resultados puesto que, como ya hemos mencionado, la optimalidad no está garantizada. En la sección tercera de este capítulo se recogen los principales métodos para medir la calidad y eficiencia de un algoritmo y poder determinar su valía frente a otros.

1.1 Problemas Estructurados

El objeto de esta sección no es únicamente dar una colección de ejemplos reales, sino el de establecer modelos que han sido muy estudiados. Así, al enfrentarse el lector a un problema dado, tratará de reconocer las estructuras especiales que aparecen en estos modelos y de esta forma se podrá aprovechar la extensa literatura y experiencia computacional al respecto. Además, no debemos olvidar la limitada, pero significativa, importancia práctica de estos modelos.

Problema de la Mochila

Se tienen n objetos donde cada objeto j tiene un peso w_j y un valor v_j . El problema consiste en seleccionar los objetos a incluir en una mochila sin exceder el peso máximo W , de modo que el valor total de los mismos sea máximo.

Para formular el problema se define una variable x_i , por cada objeto i , de modo que vale 1 si el objeto es seleccionado y 0 en caso contrario.

$$\begin{aligned} & \text{MAX } v_1x_1 + v_2x_2 + \dots + v_nx_n \\ & \text{s.a.:} \\ & \quad w_1x_1 + w_2x_2 + \dots + w_nx_n \leq W \\ & \quad x \geq 0, \text{ entero} \end{aligned}$$

Este problema tiene numerosas aplicaciones tales como:

- La denominada *Cutting Stock*, en donde hay que cortar una plancha de acero en diferentes piezas.
- Determinar los artículos que puede almacenar un depósito para maximizar su valor total.
- Maximizar el beneficio en asignación de inversiones cuando sólo hay una restricción.

Problema del Cubrimiento de Conjuntos

Este problema, también conocido como “*Set Covering*”, se puede enunciar del siguiente modo: Sea un conjunto de objetos $S = \{1, 2, \dots, m\}$ y una clase H de subconjuntos de S , $H = \{H_1, H_2, \dots, H_n\}$ donde cada H_i tiene un coste c_i asociado. El problema consiste en cubrir con coste mínimo todos los elementos de S con subconjuntos H_i .

Para formular el problema se define una variable x_i que vale 1 si H_i está en la solución y 0 en otro caso. También se introduce una matriz $A=\{a_{ij}\}$ en donde el a_{ij} vale 1 si el elemento j de S está en H_i y 0 en otro caso.

$$\begin{aligned} \text{MIN } & c_1x_1+c_2x_2+\dots+c_nx_n \\ \text{s.a.:} & \\ & a_{1j}x_1+a_{2j}x_2+\dots+a_{mj}x_n \geq 1 \quad j=1,\dots,m \\ & x_i = 1,0 \quad i=1,\dots,n \end{aligned}$$

Este problema tiene diferentes aplicaciones, entre las que podemos destacar la localización de servicios, tales como hospitales, bomberos, etc. y, la asignación de tripulaciones a vuelos.

El problema del Set Covering es relativamente fácil de resolver con métodos de Ramificación y Acotación ya que la solución óptima del problema lineal coincide, en ocasiones, con la del entero o está bastante cerca de él. La dificultad del problema viene del número enorme de variables que suelen aparecer en problemas reales.

Problema del Empaquetado de Conjuntos

A este problema también se le conoce como *Set Packing*. Como en el problema anterior se tienen los conjuntos S y H , pero ahora cada H_i tiene un valor asociado. El objetivo es empaquetar tantos elementos de S como sea posible de forma que el beneficio obtenido sea máximo y no haya solapamientos (ningún elemento de S puede aparecer mas de una vez).

En cierto modo, la relajación lineal del Set Covering y la del Set Packing son problemas duales. Sin embargo esto no sirve para establecer una relación entre los problemas enteros originales.

Uno de los ejemplos/aplicaciones es el problema del **Acoplamiento Máximo** o *Matching*. Un acoplamiento es un subconjunto de las aristas de un grafo de manera que cualquier vértice no sea incidente con más de una de esas aristas. El problema del acoplamiento máximo consiste en encontrar un acoplamiento de máximo cardinal.

Problema de la Partición de Conjuntos

Este problema también es conocido como *Set Partitioning* y, al igual que en los dos anteriores, se tienen los conjuntos S y H . Así como en el Set Covering cada elemento de S tiene que aparecer al menos en uno de H , en este problema cada elemento de S tiene que aparecer exactamente en uno de H , por lo tanto la solución representa una partición del conjunto S . La función objetivo puede ser maximizar o minimizar, según la aplicación.

Aplicaciones:

- Asignación de tripulaciones en una versión más restringida que la anteriormente mencionada.
- Creación de distritos Electorales: Asignación de electores a un colegio electoral.

Los tres problemas vistos pueden ser muy útiles para mostrar la transformación y relaciones entre problemas. Así podemos ver que el Set Packing y el Set Partitioning son equivalentes. Para pasar del primero al segundo basta con añadir variables de holgura. La transformación inversa se realiza mediante variables artificiales. Estos dos problemas son más “fáciles” de resolver de forma exacta que el Set Covering ya que en ellos las restricciones lineales están más ajustadas respecto al conjunto de soluciones enteras posibles, por lo que los óptimos de las relajaciones lineales están más cerca de las soluciones enteras.

Problema del Viajante

Este problema, también conocido como *Traveling Salesman Problem (TSP)*, ha sido uno de los mas estudiados en Investigación Operativa, por lo que merece una atención especial. Cuando la teoría de la Complejidad Algorítmica se desarrolló, el TSP fue uno de los primeros problemas en estudiarse, probando Karp en 1972 que pertenece a la clase de los problemas difíciles (NP-hard).

Desde los métodos de Ramificación y Acotación hasta los basados en la Combinatoria Polidédrica, pasando por los procedimientos Metaheurísticos, todos han sido inicialmente probados en el TSP, convirtiéndose éste en una prueba obligada para “validar” cualquier técnica de resolución de problemas enteros o combinatorios. La

librería TSPLIB (Reinelt, 1991) de dominio público contiene un conjunto de ejemplos del TSP con la mejor solución obtenida hasta la fecha y, en algunos casos, con la solución óptima. A efectos de medir empíricamente la bondad de los algoritmos que se describen en los capítulos segundo y tercero, consideraremos un conjunto de 30 ejemplos de la TSPLIB basados en problemas reales con óptimos conocidos.

El Problema del Viajante puede enunciarse del siguiente modo:

“Un viajante de comercio ha de visitar n ciudades, comenzando y finalizando en su propia ciudad. Conociendo el coste de ir de cada ciudad a otra, determinar el recorrido de coste mínimo.”

Para enunciar el problema formalmente introducimos la siguiente terminología: Sea un grafo $G=(V,A,C)$ donde V es el conjunto de vértices, A es el de aristas y $C=(c_{ij})$ es la matriz de costes. Esto es, c_{ij} es el coste o distancia de la arista (i, j) .

- Un **camino** (o cadena) es una sucesión de aristas (e_1, e_2, \dots, e_k) en donde el vértice final de cada arista coincide con el inicial de la siguiente. También puede representarse por la sucesión de vértices utilizados.
- Un **camino** es **simple** o elemental si no utiliza el mismo vértice mas de una vez.
- Un **ciclo** es un camino (e_1, e_2, \dots, e_k) en el que el vértice final de e_k coincide con el inicial de e_1 .
- Un **ciclo** es **simple** si lo es el camino que lo define.
- Un **subtour** es un ciclo simple que no pasa por todos los vértices del grafo.
- Un **tour** o **ciclo hamiltoniano** es un ciclo simple que pasa por todos los vértices del grafo.

El Problema del Viajante consiste en determinar un tour de coste mínimo. La figura 2 muestra un grafo de 8 vértices en el que aparece destacado un ciclo hamiltoniano.




Figura 1. Ciclo Hamiltoniano

Consideraremos, sin pérdida de generalidad, que el grafo es completo; es decir, que para cada par de vértices existe una arista que los une. Notar que, de no ser así, siempre podemos añadir una arista ficticia entre dos vértices con el coste del camino más corto que los une. Así por ejemplo, en el grafo de la figura 2 podemos añadir una arista entre los vértices 1 y 6 con coste 9 correspondiente al camino 1-3-6.

Entre las aplicaciones más importantes del TSP podemos destacar:

- Fabricación de circuitos integrados
- Rutas de vehículos
- Recogida (robotizada) de material en almacenes
- Instalación de componentes en ordenadores
- Aparece como subproblema en otras aplicaciones

Este problema puede ser formulado mediante un modelo de programación lineal entera con variables binarias. Para ello basta considerar las variables x_{ij} que valen 1 si el viajante va de la ciudad i a la j y 0 en otro caso y llamar c_{ij} al coste de ir de la ciudad i a la j :

$$\begin{aligned}
& \text{MIN} \quad \sum_{i < j} c_{ij} x_{ij} \\
& \text{s.a.:} \\
& \sum_{i < j} x_{ij} + \sum_{j < i} x_{ji} = 2 \quad i = 1, 2, \dots, n \\
& \sum_{(i,j) \in \partial(S)} x_{ij} \geq 2 \quad \forall S \subseteq \{1, 2, \dots, n\}, \quad 3 \leq |S| \leq [n/2] \\
& x_{ij} = 0, 1 \quad \forall i < j
\end{aligned}$$

Donde $\partial(S)$ representa el conjunto de aristas incidentes con exactamente un vértice de S .

Las restricciones que aparecen en segundo lugar (vinculadas a todos los subconjuntos de vértices S) reciben el nombre de restricciones de *eliminación de subtours* y garantizan que la solución sea un tour. El problema es que al haber una por cada subconjunto del conjunto de vértices, aparecen en una cantidad del orden de 2^n , lo cual hace inmanejable tal formulación. Se han encontrado restricciones alternativas para evitar la formación de subtours que suponen la incorporación de una cantidad polinómica de restricciones (Miller, Tucker y Zemlin, 1960). Aún así, la resolución óptima del problema ha resultado poco eficiente, salvo para ejemplos relativamente pequeños, dado el elevado tiempo de computación requerido por cualquier método exacto.

Problema de la Asignación Cuadrática

Introduciremos el problema mediante el siguiente ejemplo: “Se tienen n módulos electrónicos y n posiciones en donde situarlos sobre una placa. Sea t_{ik} el número de cables que conectan los módulos i y k , y sea d_{jl} la distancia entre las posiciones j y l de la placa. El problema consiste en determinar la ubicación de los módulos minimizando la longitud total del cable utilizado”

Al igual que en los otros modelos de asignación vistos, se introducen variables x_{ij} que valen 1 si el módulo i se asigna a la posición j y 0 en otro caso.

$$\begin{aligned}
& \text{MIN} \quad \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n \sum_{l=1}^n t_{ik} d_{jl} x_{ij} x_{kl} \\
& \text{s.a.:} \\
& \sum_{j=1}^n x_{ij} = 1 \quad i = 1, 2, \dots, n \\
& \sum_{i=1}^n x_{ij} = 1 \quad j = 1, 2, \dots, n \\
& x_{ij} = 0, 1
\end{aligned}$$

El problema se llama cuadrático por la función objetivo ya que el coste viene dado por parejas de variables que aparecen como producto. Así pues la función objetivo es no lineal, aunque se puede transformar en un problema lineal entero introduciendo variables que representen a los productos. Notar que esta transformación obligaría a reformular las restricciones.

Este problema tiene numerosas aplicaciones ya que podemos encontrar en ámbitos muy diversos situaciones como la descrita. Así, por ejemplo, el problema de ubicar determinados servicios (como laboratorios, rayos X, etc.) en un hospital en donde se conoce el flujo previsto de personal entre tales servicios. Análogamente el guardar determinados productos en un almacén.

El objeto de introducir este problema es doble: por una parte mostrar un problema no lineal, con un gran número de aplicaciones prácticas, que puede transformarse en un PLE y, por otra, presentar uno de los problemas más difíciles (sino el que más) dentro de los ya de por sí difíciles problemas enteros.

Problema de Asignación Generalizada

Se tiene un conjunto $J=\{1,2,...,n\}$ de índices de los trabajos a realizar y otro conjunto $I=\{1,2,...,m\}$ de personas para realizarlos. El coste (o valor) de asignar la persona i al trabajo j viene dado por c_{ij} . Además se tiene una disponibilidad b_i de recursos de la persona i (como por ejemplo horas de trabajo) y una cantidad a_{ij} de recursos de la persona i necesarias para realizar el trabajo j . Con todo esto, el problema consiste en asignar las personas a los trabajos con el mínimo coste (o el máximo valor).

Al igual que en los otros modelos de asignación vistos, se introducen variables x_{ij} que valen 1 si la persona i se asigna al trabajo j y 0 en otro caso.

$$\begin{aligned} \text{MIN} \quad & \sum_{i=1}^n \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s.a.:} \quad & \sum_{i=1}^n x_{ij} = 1 \quad j = 1, 2, \dots, n \\ & \sum_{j=1}^n a_{ij} x_{ij} \leq b_i \quad i = 1, 2, \dots, n \\ & x_{ij} = 0, 1 \end{aligned}$$

En este modelo de asignación se puede asignar una persona a más de un trabajo, respetando obviamente las limitaciones en los recursos.

Algunas de las aplicaciones mas relevantes son:

- Asignación de clientes a camiones (de reparto o recogida) de mercancías.
- Asignación de tareas a programadores.
- Asignación de trabajos a una red de ordenadores.

Problema de la Ordenación Lineal

Este problema consiste en determinar una permutación p de las filas y columnas de una matriz cuadrada dada, de manera que la suma de los elementos por encima de la diagonal sea máxima. Notar que la permutación p proporciona el orden tanto de las filas como de las columnas.

En términos económicos este problema es equivalente al de triangulación de matrices input-output, que puede describirse del siguiente modo: La economía de una región se divide en m sectores, se construye una matriz $m \times m$ donde la entrada a_{ij} denota la cantidad de mercancías (en valor monetario) que el sector i sirve al j en un año dado. El problema de triangulación consiste en permutar las filas y columnas de la matriz simultáneamente de manera que la suma de elementos por encima de la diagonal sea lo mayor posible. Una solución óptima presenta una ordenación de sectores de modo que los proveedores (sectores que producen para otros) van en primer lugar seguidos de los consumidores.

Este problema también puede enunciarse en términos de grafos, lo cual ayuda a formularlo del siguiente modo:

$$\begin{aligned} \text{MAX} \quad & \sum_{i=1}^n \sum_{j=1}^n c_{ij} x_{ij} \\ \text{s.a.:} \quad & x_{ij} + x_{ji} = 1 \quad \forall i, j \in V, \quad i \neq j \\ & x_{ij} + x_{jk} + x_{ki} \leq 2 \quad 1 \leq i < j < k \leq n \\ & x_{ij} \text{ binaria} \end{aligned}$$

donde $x_{ij}=1$ representa que el sector (vértice) i precede al j en la ordenación dada por la solución.

1.2 Medidas de Calidad de un Algoritmo

Un buen algoritmo heurístico debe de tener las siguientes propiedades:

1. **Eficiente.** Un esfuerzo computacional realista para obtener la solución.
2. **Bueno.** La solución debe de estar, en promedio, cerca del óptimo.
3. **Robusto.** La probabilidad de obtener una mala solución (lejos del óptimo) debe ser baja.

Para medir la calidad de un heurístico existen diversos procedimientos, entre los que se encuentran los siguientes:

Comparación con la solución óptima

Aunque normalmente se recurre al algoritmo aproximado por no existir un método exacto para obtener el óptimo, o por ser éste computacionalmente muy costoso, en ocasiones puede que dispongamos de un procedimiento que proporcione el óptimo para un conjunto limitado de ejemplos (usualmente de tamaño reducido). Este conjunto de ejemplos puede servir para medir la calidad del método heurístico.

Normalmente se mide, para cada uno de los ejemplos, la desviación porcentual de la solución heurística frente a la óptima, calculando posteriormente el promedio de dichas desviaciones. Si llamamos c_h al coste de la solución del algoritmo heurístico y c_{opt} al coste de la solución óptima de un ejemplo dado, en un problema de

minimización la desviación porcentual viene dada por la expresión: $\frac{c_h - c_{opt}}{c_{opt}} \cdot 100$.

Comparación con una cota

En ocasiones el óptimo del problema no está disponible ni siquiera para un conjunto limitado de ejemplos. Un método alternativo de evaluación consiste en comparar el valor de la solución que proporciona el heurístico con una cota del problema (inferior si es un problema de minimización y superior si es de maximización). Obviamente la bondad de esta medida dependerá de la bondad de la cota (cercanía de ésta al óptimo), por lo que, de alguna manera, tendremos que tener información de lo buena que es dicha cota. En caso contrario la comparación propuesta no tiene demasiado interés.

Comparación con un método exacto truncado

Un método enumerativo como el de Ramificación y Acotación explora una gran cantidad de soluciones, aunque sea únicamente una fracción del total, por lo que los problemas de grandes dimensiones pueden resultar computacionalmente inabordables con estos métodos. Sin embargo, podemos establecer un límite de iteraciones (o de tiempo) máximo de ejecución para el algoritmo exacto. También podemos saturar un nodo en un problema de maximización cuando su cota inferior sea menor o igual que la cota superior global más un cierto α (análogamente para el caso de minimizar). De esta forma se garantiza que el valor de la mejor solución proporcionada por el procedimiento no dista más de α del valor óptimo del problema. En cualquier caso, la mejor solución encontrada con estos procedimientos truncados proporciona una cota con la que contrastar el heurístico.

Comparación con otros heurísticos

Este es uno de los métodos más empleados en problemas difíciles (NP-duros) sobre los que se ha trabajado durante tiempo y para los que se conocen algunos buenos heurísticos. Al igual que ocurre con la comparación con las cotas, la conclusión de dicha comparación está en función de la bondad del heurístico escogido.

Análisis del peor caso

Uno de los métodos que durante un tiempo tuvo bastante aceptación es analizar el comportamiento en el peor caso del algoritmo heurístico; esto es, considerar los ejemplos que sean mas desfavorables para el algoritmo y acotar analíticamente la máxima desviación respecto del óptimo del problema. Lo mejor de este método es que acota el resultado del algoritmo para cualquier ejemplo; sin embargo, por esto mismo, los resultados no suelen ser representativos del comportamiento medio del algoritmo. Además, el análisis puede ser muy complicado para los heurísticos más sofisticados.

Aquellos algoritmos que, para cualquier ejemplo, producen soluciones cuyo coste no se aleja de un porcentaje ε del coste de la solución óptima, se llaman *Algoritmos ε -Aproximados*. Esto es; en un problema de minimización se tiene que cumplir para un $\varepsilon > 0$ que:

$$c_h \leq (1 + \varepsilon) c_{opt}$$

2. Métodos Constructivos en el Problema del Viajante

Los métodos constructivos son procedimientos iterativos que, en cada paso, añaden un elemento hasta completar una solución. Usualmente son métodos deterministas y están basados en seleccionar, en cada iteración, el elemento con mejor evaluación. Estos métodos son muy dependientes del problema que resuelven, por lo que utilizaremos el problema del viajante para describirlos. En este capítulo se describen cuatro de los métodos más conocidos para el TSP tal y como aparecen en la revisión realizada por Jünger, Reinelt y Rinaldi (1995).

2.1 Heurísticos del Vecino mas Próximo

Uno de los heurísticos mas sencillos para el TSP es el llamado “del vecino mas cercano”, que trata de construir un ciclo Hamiltoniano de bajo coste basándose en el vértice cercano a uno dado. Este algoritmo es debido a Rosenkrantz, Stearns y Lewis (1977) y su código, en una versión standard, es el siguiente:

Algoritmo del Vecino más Próximo

Inicialización

Seleccionar un vértice j al azar.

Hacer $t = j$ y $W = V \setminus \{j\}$.

Mientras ($W \neq \emptyset$)

Tomar j de $W / c_{ij} = \min \{c_{it} / i \text{ en } W\}$

Conectar t a j

Hacer $W = W \setminus \{j\}$ y $t = j$.

Este procedimiento realiza un número de operaciones de orden $O(n^2)$. Si seguimos la evolución del algoritmo al construir la solución de un ejemplo dado, veremos que comienza muy bien, seleccionando aristas de bajo coste. Sin embargo, al final del proceso probablemente quedarán vértices cuya conexión obligará a introducir aristas de coste elevado. Esto es lo que se conoce como **miopía** del procedimiento, ya que, en una iteración escoge la mejor opción disponible sin “ver” que esto puede obligar a realizar malas elecciones en iteraciones posteriores.

El algoritmo tal y como aparece puede ser programado en unas pocas líneas de código. Sin embargo una implementación directa será muy lenta al ejecutarse sobre ejemplos de gran tamaño (10000 vértices). Así pues, incluso para un heurístico tan sencillo como éste, es importante pensar en la eficiencia y velocidad de su código.

Para reducir la miopía del algoritmo y aumentar su velocidad se introduce el concepto de subgrafo candidato, junto con algunas modificaciones en la exploración. Un **subgrafo candidato** es un subgrafo del grafo completo con los n vértices y únicamente las aristas consideradas “atractivas” para aparecer en un ciclo Hamiltoniano de bajo coste. Una posibilidad es tomar, por ejemplo, el *subgrafo de los k vecinos más cercanos*; esto es, el subgrafo con los n vértices y para cada uno de ellos las aristas que lo unen con los k vértices más cercanos. Este subgrafo también será usado en otros procedimientos.

El algoritmo puede “mejorarse” en los siguientes aspectos:

- Para seleccionar el vértice j que se va a unir a t (y por lo tanto al tour parcial en construcción), en lugar de examinar todos los vértices, se examinan únicamente los adyacentes a t en el subgrafo candidato. Si todos ellos están ya en el tour parcial, entonces sí que se examinan todos los posibles.
- Cuando un vértice queda conectado (con grado 2) al tour en construcción, se eliminan del subgrafo candidato las aristas incidentes con él.
- Se especifica un número $s < k$ de modo que cuando un vértice que no está en el tour está conectado únicamente a s o menos aristas del subgrafo candidato se considera que se está quedando aislado. Por ello se inserta inmediatamente en el tour. Como punto de inserción se toma el mejor de entre los k vértices mas cercanos presentes en el tour.

Considerando el estudio empírico sobre las 30 ejemplos utilizados, la versión inicial del algoritmo presenta un porcentaje de desviación en promedio respecto del óptimo de 24.2%, mientras que la mejorada con $k=10$ y $s=4$ de 18.6%. La primera tiene un tiempo de ejecución medio de 15.3 segundos mientras que la segunda lo tiene de 0.3 segundos.

2.2 Heurísticos de Inserción

Otra aproximación intuitiva a la resolución del TSP consiste en comenzar construyendo ciclos que visiten únicamente unos cuantos vértices, para posteriormente extenderlos insertando los vértices restantes. En cada paso se inserta un nuevo vértice en el ciclo hasta obtener un ciclo Hamiltoniano. Este procedimiento es debido a los mismos autores que el anterior y su esquema es el siguiente:

Algoritmo de Inserción

Inicialización

Seleccionar un ciclo inicial (subtour) con k vértices.

Hacer $W = V \setminus \{\text{vértices seleccionados}\}$.

Mientras ($W \neq \emptyset$)

Tomar j de W de acuerdo con algún criterio preestablecido

Insertar j donde menos incremente la longitud del ciclo

Hacer $W = W \setminus \{j\}$.

Existen varias posibilidades para implementar el esquema anterior de acuerdo con el criterio de selección del vértice j de W a insertar en el ciclo. Se define la distancia de un vértice v al ciclo como el mínimo de las distancias de v a todos los vértices del ciclo:

$$d_{\min}(v) = \min \{ c_{iv} / i \in V \setminus W \}$$

Los criterios más utilizados son:

Inserción más cercana: Seleccionar el vértice j más cercano al ciclo.
 $d_{\min}(j) = \min \{ d_{\min}(v) / v \in W \}$

Inserción más lejana: Seleccionar el vértice j más lejano al ciclo.
 $d_{\min}(j) = \max \{ d_{\min}(v) / v \in W \}$

Inserción más barata: Seleccionar el vértice j que será insertado con el menor incremento del coste.

Inserción aleatoria: Seleccionar el vértice j al azar.

La figura 2 muestra la diferencia entre estos criterios en un caso dado. El ciclo actual está formado por 4 vértices y hay que determinar el próximo a insertar. La inserción más cercana escogerá el vértice i , la más lejana el s y la más barata el k .




Figura 2. Selección del vértice a insertar

Todos los métodos presentan un tiempo de ejecución de $O(n^2)$ excepto la inserción más cercana que es de $O(n^2 \log n)$. Respecto al estudio empírico sobre los 30 grafos de la TSPLIB los porcentajes de desviación del óptimo son de 20%, 9.9%, 16.8% y 11.1% para el más cercano, mas lejano, mas barato y aleatorio, respectivamente, aunque el tiempo de ejecución del más barato es mucho mayor. Respecto al ciclo inicial se ha

tomado $k=3$ vértices y se comprueba experimentalmente que el procedimiento no depende mucho del ciclo inicial (aproximadamente un 6% de variación).

2.3 Heurísticos Basados en Árboles Generadores

Los heurísticos considerados anteriormente construyen un ciclo Hamiltoniano basándose únicamente en los costes de las aristas. Los heurísticos de este apartado se basan en el árbol generador de coste mínimo, lo que aporta una información adicional sobre la estructura del grafo. Comenzaremos por ver algunos conceptos de teoría de grafos.

- Un grafo es **conexo** si todo par de vértices está unido por un camino.
- Un **árbol** es un grafo conexo que no contiene ciclos. El número de aristas de un árbol es igual al número de vértices menos uno.
- Un **árbol generador** de un grafo $G=(V,A,C)$ es un árbol sobre todos los vértices y tiene, por tanto, $|V| - 1$ aristas de G .
- Un **árbol generador de mínimo peso** (o de coste mínimo) es aquel que de entre todos los árboles generadores de un grafo dado, presenta la menor suma de los costes de sus aristas.
- Un **acoplamiento** de un grafo $G=(V,A,C)$ es un subconjunto M del conjunto A de aristas cumpliendo que cada vértice del grafo es a lo sumo incidente con una arista de M .
- Un acoplamiento sobre un grafo $G=(V,A,C)$ es **perfecto** si es de cardinalidad máxima e igual a $\lfloor |V| / 2 \rfloor$.

Las figuras siguientes ilustran los conceptos vistos sobre un grafo completo de 8 vértices. En la figura 3 tenemos un árbol generador. Notar que contiene a todos los vértices y no hay ningún ciclo. La figura 4 muestra un acoplamiento perfecto en el que podemos ver cómo cada vértice es incidente con una, y solo una, de las aristas. Al ser un grafo de 8 vértices el número máximo de aristas en un acoplamiento es de 4, por lo que el de la figura es perfecto.




Figura 3. Árbol generador




Figura 4. Acoplamiento Perfecto

El algoritmo debido a Prim (1957) obtiene un árbol generador de mínimo peso de un grafo G completo. El algoritmo comienza por definir el conjunto T de aristas del árbol (inicialmente vacío) y, el conjunto U de vértices del árbol (inicialmente formado por uno elegido al azar). En cada paso se calcula la arista de menor coste que une U con $V \setminus U$, añadiéndola a T y pasando su vértice adyacente de $V \setminus U$ a U . El procedimiento finaliza cuando U es igual a V ; en cuyo caso el conjunto T proporciona la solución.

Dado un ciclo $v_{i0}, v_{i1}, \dots, v_{ik}$ que pasa por todos los vértices de G (no necesariamente simple), el siguiente procedimiento obtiene un ciclo Hamiltoniano comenzando en v_{i0} y terminando en v_{ik} ($v_{i0} = v_{ik}$). En el caso de grafos con costes cumpliendo la desigualdad triangular (como es el caso de grafos euclídeos), este procedimiento obtiene un ciclo de longitud menor o igual que la del ciclo de partida.

Algoritmo de Obtención de Tour

Inicialización

Hacer $T = \{ v_{i0} \}$, $v = v_{i0}$ y $s=1$.

Mientras ($|T| < |V|$)

Si v_{is} no está en T , hacer:

$T = T \cup \{ v_{is} \}$

Conectar v a v_{is} y hacer $v = v_{is}$

Hacer $s = s+1$

Conectar v a v_{i0} y formar el ciclo Hamiltoniano

A partir de los elementos descritos se puede diseñar un algoritmo para obtener un ciclo Hamiltoniano. Basta con construir un árbol generador de mínimo peso (figura 5), considerar el ciclo en el que todas las aristas del árbol son recorridas dos veces, cada vez en un sentido (figura 6), y aplicar el algoritmo de *obtención de tour* a dicho ciclo (figura 7). El ejemplo de las figuras mencionadas ilustra dicho procedimiento sobre un grafo completo con 10 vértices.




Figura 5. Árbol Generador




Figura 6. Duplicación de aristas




Figura 7. Ciclo Hamiltoniano

La figura 5 muestra un árbol generador de mínimo peso e igual a 156. En la figura 6 se han duplicado las aristas y se señala mediante flechas la dirección del ciclo resultante. Su coste obviamente será de $156 \times 2 = 312$. Aplicando el procedimiento de obtención de tour al ciclo de la figura 6, se obtiene el ciclo Hamiltoniano de la figura 7 con un coste de 258.

El proceso de duplicación de las aristas (recorrerlas todas en ambos sentidos) para obtener un tour aumenta en gran medida el coste de la solución. Podemos ver que es posible obtener un ciclo que pase por todos los vértices de G a partir de un árbol generador sin necesidad de duplicar todas las aristas. De hecho, basta con añadir aristas al árbol de modo que todos los vértices tengan grado par. El siguiente procedimiento, debido a Christofides (1976), calcula un acoplamiento perfecto de mínimo peso sobre los vértices de grado impar del árbol generador. Añadiendo al árbol las aristas del acoplamiento se obtiene un grafo con todos los vértices pares, y por lo tanto, un ciclo del grafo original, a partir del cual ya hemos visto cómo obtener un tour.

Algoritmo de Christofides

1. Calcular un Árbol Generador de Mínimo Peso
2. Obtener el conjunto de vértices de grado impar en el Árbol.
3. Obtener un Acoplamiento Perfecto de mínimo peso sobre dichos vértices.
4. Añadir las aristas del Acoplamiento al Árbol.
5. Aplicar el procedimiento de Obtención de Tour.

El cálculo del acoplamiento perfecto de coste mínimo sobre un grafo de k vértices se realiza en un tiempo $O(k^3)$ con el algoritmo de Edmonds (1965). Dado que un árbol generador de mínimo peso tiene como máximo $n-1$ hojas (vértices de grado 1 en el árbol), el procedimiento de Christofides tendrá un tiempo de orden $O(n^3)$.

Propiedad: El algoritmo de Christofides sobre ejemplos cuya matriz de distancias cumple la desigualdad triangular produce una solución cuyo valor es como mucho 1.5 veces el valor óptimo:

$$c_H \leq \frac{3}{2} c_{OPT}$$

Es decir, es un algoritmo $\frac{1}{2}$ - aproximado sobre esta clase de ejemplos.

Prueba:

Sea $c(AGMP)$ el coste del árbol generador de mínimo peso y $c(A)$ el coste del acoplamiento perfecto calculado en el algoritmo de Christofides. Al añadir las aristas del acoplamiento al árbol se obtiene un ciclo (con posibles repeticiones) cuyo coste es la suma de ambos costes. Dado que la matriz de distancias cumple la desigualdad triangular, al aplicar el algoritmo de obtención de tour el coste puede reducirse eventualmente. Por ello el coste de la solución obtenida, c_H , cumple:

$$c_H \leq c(AGMP) + c(A) \quad (1)$$

Un árbol generador de mínimo peso, por construcción, tiene un coste menor que cualquier ciclo Hamiltoniano y, por lo tanto, que el ciclo Hamiltoniano de coste mínimo (tour óptimo). Para probarlo basta con considerar un ciclo Hamiltoniano y quitarle una arista, con lo que se obtiene un árbol generador. El árbol generador de mínimo peso tiene, obviamente, un coste menor que dicho árbol generador y, por lo tanto, que el ciclo Hamiltoniano. Luego:

$$c(AGMP) \leq c_{OPT} \quad (2)$$

El acoplamiento del paso 3 del algoritmo de Christofides tiene un coste menor o igual que la mitad de la longitud de un tour óptimo en un grafo Euclídeo. Para probarlo consideremos un tour óptimo y llamemos S al conjunto de vértices de grado impar en el árbol. El algoritmo calcula un acoplamiento perfecto de coste mínimo sobre los vértices de S . La figura 8 muestra un ciclo Hamiltoniano óptimo y los vértices de S en oscuro. Además aparecen dos acoplamientos perfectos sobre S , A_1 (trazo continuo) y A_2 (trazo discontinuo), en donde cada vértice está acoplado al más próximo en el tour óptimo.




Figura 8. Dos acoplamientos sobre S

Como se cumple la desigualdad triangular, se tiene que $c(A_1) + c(A_2) \leq c_{OPT}$. Es evidente que por ser el de coste mínimo $c(A) \leq c(A_1)$ y $c(A) \leq c(A_2)$, de donde:

$$2c(A) \leq c_{OPT} \quad (3)$$

De (1), (2) y (3) se concluye el resultado.

Las figuras siguientes ilustran el método de Christofides sobre el mismo ejemplo de las figuras 5, 6 y 7. En la figura 9 aparecen oscurecidos los vértices de grado impar en el árbol generador, y en trazo discontinuo las aristas del acoplamiento perfecto de coste mínimo sobre tales vértices. Al añadirlas se obtiene un tour de coste 199. La figura 10 muestra el ciclo Hamiltoniano que se obtiene al aplicarle el procedimiento de obtención del ciclo al tour de la figura anterior. La solución tiene un coste de 203, mientras que la obtenida con el procedimiento de duplicar aristas (figura 7) tenía un coste de 258.




Figura 9. Acoplamiento Perfecto




Figura 10. Ciclo Hamiltoniano.

El procedimiento del árbol generador y posterior duplicación de aristas obtiene, sobre el conjunto de ejemplos considerados de la TSPLIB, una desviación del óptimo de 38%, mientras que el heurístico de Christofides de 19.5%.

2.4 Heurísticos Basados en Ahorros

Los métodos de esta sección son debidos a Clarke y Wright (1964) y fueron propuestos inicialmente para problemas de rutas de vehículos. Veamos una adaptación de estos procedimientos al problema del viajante.

El algoritmo siguiente se basa en combinar sucesivamente subtours hasta obtener un ciclo Hamiltoniano. Los subtours considerados tienen un vértice común llamado *base*. El procedimiento de unión de subtours se basa en eliminar las aristas que conectan dos vértices de diferentes subtours con el vértice base, uniendo posteriormente los vértices entre sí. Llamamos *ahorro* a la diferencia del coste entre las aristas eliminadas y la añadida.

Algoritmo de Ahorros

Inicialización

Tomar un vértice $z \in V$ como *base*.

Establecer los $n-1$ subtours $[(z,v),(v,z)] \quad \forall v \in V \setminus \{z\}$.

Mientras (Queden dos o mas subtours)

Para cada par de subtours calcular el ahorro de unirlos al eliminar en cada uno una de las aristas que lo une con z y conectar los dos vértices asociados.

Unir los dos subtours que produzcan un ahorro mayor.

En las figuras 11 y 12 se ilustra una iteración del procedimiento. Podemos ver cómo se combinan dos subtours eliminando las aristas de los vértices i y j al vértice base z , e insertando la arista (i,j) .




Figura 11. Conjunto inicial de subtours




Figura 12. Conjunto final de subtours

En la implementación del algoritmo se tiene que mantener una lista con las combinaciones posibles. El punto clave de la implementación es la actualización de esta lista. Sin embargo, al unir dos subtours únicamente se ven afectados aquellos en los que su “mejor conexión” pertenece a alguno de los dos subtours recién unidos. Luego basta con actualizar estos en cada iteración sin necesidad de actualizarlos todos cada vez que se realiza una unión.

Al igual que en otros heurísticos, podemos utilizar el subgrafo candidato (en el que están todos los vértices y sólo las aristas consideradas “atractivas”) para acelerar los cálculos. Así, al actualizar la lista de la mejores conexiones únicamente se consideran aristas del subgrafo candidato.

El método presenta un tiempo de ejecución de $O(n^3)$. Respecto al estudio empírico sobre los 30 ejemplos de la TSPLIB los porcentajes de desviación respecto del óptimo son de 9.8% para el método original y 9.6% para el mejorado con el uso del subgrafo candidato. Además, el tiempo de ejecución es mucho menor para este último.

La siguiente tabla recoge los resultados del estudio comparativo sobre los cuatro algoritmos descritos, con los 30 ejemplos de la TSPLIB considerados:

Heurístico	Desviación del Óptimo	T. Ejecución (pr2392)
Vecino más Próximo	18.6%	0.3
Inserción más Lejana	9.9%	35.4
Christofides	19.5%	0.7
Ahorros	9.6%	5.07

Todos los métodos están basados en cálculos relativamente sencillos y han sido implementados eficientemente, por lo que los tiempos de computación son muy parecidos entre sí e inferiores a 1 segundo en promedio. Por

ello, para distinguir entre todos, en la tabla se muestra el tiempo en segundos sobre el ejemplo de mayor tamaño considerado (pr2392) de casi 2400 vértices.

A la vista de los resultados podemos concluir que tanto el método de los ahorros como el de inserción basado en el elemento más lejano son los que mejores resultados obtienen, aunque presentan un tiempo de computación mayor que los otros dos.

3. Métodos de Búsqueda Local en el Problema del Viajante

En general, las soluciones obtenidas con los métodos constructivos suelen ser de una calidad moderada. En este apartado vamos a estudiar diversos algoritmos basados en la búsqueda local para mejorarlas. Al igual que ocurría con los métodos descritos en la sección anterior, estos algoritmos son muy dependientes del problema que resuelven, por lo que al igual que allí, utilizaremos el TSP para describirlos. Específicamente, consideraremos tres de los métodos más utilizados, tal y como aparecen descritos en Jünger, Reinelt y Rinaldi (1995). Comenzaremos por definir y explicar algunos de los conceptos genéricos de estos métodos.

Los procedimientos de búsqueda local, también llamados de mejora, se basan en explorar el entorno o vecindad de una solución. Utilizan una operación básica llamada movimiento que, aplicada sobre los diferentes elementos de una solución, proporciona las soluciones de su entorno. Formalmente:

Definición: Sea X el conjunto de soluciones del problema combinatorio. Cada solución x tiene un conjunto de soluciones asociadas $N(x) \subseteq X$, que denominaremos *entorno* de x .

Definición: Dada una solución x , cada solución de su entorno, $x' \in N(x)$, puede obtenerse directamente a partir de x mediante una operación llamada *movimiento*.

Un procedimiento de búsqueda local parte de una solución inicial x_0 , calcula su entorno $N(x_0)$ y escoge una nueva solución x_1 en él. Dicho de otro modo, realiza el movimiento m_1 que aplicado a x_0 da como resultado x_1 . Este proceso puede ser aplicado reiteradamente tal y como muestra el diagrama siguiente:

$$x_0 \xrightarrow{m_1} x_1 \xrightarrow{m_2} x_2 \xrightarrow{m_3} x_3$$

Un procedimiento de búsqueda local queda determinado al especificar un entorno y el criterio de selección de una solución dentro del entorno.

La definición de entorno/movimiento, depende en gran medida de la estructura del problema a resolver, así como de la función objetivo. También se pueden definir diferentes criterios para seleccionar una nueva solución del entorno. Uno de los criterios más simples consiste en tomar la solución con mejor evaluación de la función objetivo, siempre que la nueva solución sea mejor que la actual. Este criterio, conocido como *greedy*, permite ir mejorando la solución actual mientras se pueda. El algoritmo se detiene cuando la solución no puede ser mejorada. A la solución encontrada se le denomina *óptimo local respecto al entorno definido*.

El óptimo local alcanzado no puede mejorarse mediante el movimiento definido. Sin embargo, el método empleado no permite garantizar, de ningún modo, que sea el óptimo global del problema. Más aún, dada la “miopía” de la búsqueda local, es de esperar que en problemas de cierta dificultad, en general no lo sea.

La figura 13 muestra el espacio de soluciones de un problema de maximización de dos dimensiones donde la altura del gráfico mide el valor de la función objetivo. Se considera un procedimiento de búsqueda local greedy iniciado a partir de una solución x_0 con valor 5 y que realiza 8 movimientos de mejora hasta alcanzar la solución x_8 con valor 13. La figura muestra cómo x_8 es un óptimo local y cualquier movimiento que se le aplique proporcionará una solución con peor valor. Podemos ver cómo el óptimo global del problema, con un valor de 15, no puede ser alcanzado desde x_8 , a menos que permitamos realizar movimientos que empeoren el valor de las soluciones y sepamos dirigir correctamente la búsqueda




Figura 13. Óptimo local y global

Esta limitación de la estrategia greedy es el punto de partida de los procedimientos meta-heurísticos basados en búsqueda local: evitar el quedar atrapados en un óptimo local lejano del global. Para lo cual, como hemos visto, se hace preciso el utilizar movimientos que empeoren la función objetivo. Sin embargo esto plantea dos problemas. El primero es que al permitir movimientos de mejora y de no mejora, el procedimiento se puede ciclar, revisitando soluciones ya vistas, por lo que habría que introducir un mecanismo que lo impida. El segundo es que hay que establecer un criterio de parada ya que un procedimiento de dichas características podría iterar indefinidamente. Los procedimientos meta-heurísticos incorporan mecanismos sofisticados para solucionar eficientemente ambas cuestiones así como para tratar, en la medida de lo posible, de dirigir la búsqueda de forma inteligente.

Pese a la miopía de los métodos de búsqueda local simples, suelen ser muy rápidos y proporcionan soluciones que, en promedio, están relativamente cerca del óptimo global del problema. Además, dichos métodos suelen ser el punto de partida en el diseño de algoritmos meta-heurísticos más complejos. En este apartado vamos a estudiar algunos métodos heurísticos de búsqueda local para el problema del viajante.

3.1 Procedimientos de 2 intercambio

Este procedimiento está basado en la siguiente observación para grafos euclídeos. Si un ciclo Hamiltoniano se cruza a si mismo, puede ser fácilmente acortado, basta con eliminar las dos aristas que se cruzan y reconectar los dos caminos resultantes mediante aristas que no se corten. El ciclo final es más corto que el inicial.

Un *movimiento 2-opt* consiste en eliminar dos aristas y reconectar los dos caminos resultantes de una manera diferente para obtener un nuevo ciclo. Las figuras 14 y 15 ilustran este movimiento en el que las aristas (i,j) y (l,k) son reemplazadas por (l,j) y (i,k) . Notar que sólo hay una manera de reconectar los dos caminos formando un único tour.




Figura 14. Solución original




Figura 15. Solución mejorada

El siguiente código recoge el algoritmo heurístico de mejora 2-óptimo. Consiste en examinar todos los vértices, realizando, en cada paso, el mejor movimiento 2-opt asociado a cada vértice.

Algoritmo 2-óptimo*Inicialización*

Considerar un ciclo Hamiltoniano inicial
move = 1

Mientras (move = 1)

move=0. Etiquetar todos los vértices como no explorados.

Mientras(Queden vértices por explorar)

Seleccionar un vértice i no explorado.

Examinar todos los movimientos 2-opt que incluyan la arista de i a su sucesor en el ciclo. Si alguno de los movimientos examinados reduce la longitud del ciclo, realizar el mejor de todos y hacer move = 1. En otro caso etiquetar i como explorado.

La variable *move* vale 0 si no se ha realizado ningún movimiento al examinar todos los vértices, y 1 en otro caso. El algoritmo finaliza cuando *move=0*, con lo que queda garantizado que no existe ningún movimiento 2-opt que pueda mejorar la solución.

El orden en el que el algoritmo examina los nodos incide de manera notable en su funcionamiento. En una implementación sencilla podemos considerar el orden natural 1,2,...,n. Sin embargo, es fácil comprobar que cuando se realiza un movimiento hay muchas posibilidades de encontrar movimientos de mejora asociados a los vértices que han intervenido en el movimiento recién realizado. Por ello, una implementación más eficiente consiste en considerar una lista de vértices candidatos a examinar. El orden inicial es el de los vértices en el ciclo comenzando por uno arbitrario y en cada iteración se examina el primero de la lista. Cada vez que se examina un vértice *i*, éste se coloca al final de la lista y, los vértices involucrados en el movimiento (vértices *j*, *k* y *l* de la figura 15) se insertan en primer lugar.

Dado que el proceso de examinar todos los movimientos 2-opt asociados a cada vértice es muy costoso computacionalmente, se pueden introducir las siguientes mejoras para acelerar el algoritmo:

- Exigir que al menos una de las dos aristas añadidas en cada movimiento, para formar la nueva solución, pertenezca al *subgrafo candidato*.
- Observando el funcionamiento del algoritmo se puede ver que en las primeras iteraciones la función objetivo decrece substancialmente, mientras que en las últimas apenas se modifica. De hecho la última únicamente verifica que es un óptimo local al no realizar ningún movimiento. Por ello, si interrumpimos el algoritmo antes de su finalización, ahorraremos bastante tiempo y no perderemos mucha calidad.

Es evidente que ambas mejoras reducen el tiempo de computación a expensas de perder la garantía de que la solución final es un óptimo local. Así pues, dependiendo del tamaño del ejemplo a resolver, así como de lo crítico que sea el tiempo de ejecución, se deben implementar o no.

El comprobar si existe, o no, un movimiento 2-opt de mejora utiliza un tiempo de orden $O(n^2)$, ya que hay que examinar todos los pares de aristas en el ciclo. Podemos encontrar clases de problemas para los que el tiempo de ejecución del algoritmo no está acotado polinómicamente. Respecto al estudio empírico sobre los ejemplos de la TSPLIB considerados, partiendo de la solución del algoritmo del vecino más próximo, el promedio de desviación del óptimo es del 8.3%.

3.2 Procedimientos de k - intercambio

Para introducir mayor flexibilidad al modificar un ciclo Hamiltoniano, podemos considerar el dividirlo en *k* partes, en lugar de dos, y combinar los caminos resultantes de la mejor manera posible. Llamamos movimiento *k-opt* a tal modificación.

Es evidente que al aumentar *k* aumentará el tamaño del entorno y el número de posibilidades a examinar en el movimiento, tanto por las posibles combinaciones para eliminar las aristas del ciclo, como por la reconstrucción posterior. El número de combinaciones para eliminar *k* aristas en un ciclo viene dado por el número $\binom{n}{k}$

Examinar todos los movimientos *k-opt* de una solución lleva un tiempo del orden de $O(n^k)$ por lo que, para valores altos de *k*, sólo es aplicable a ejemplos de tamaño pequeño.

En este apartado vamos a estudiar el caso de $k=3$ y además impondremos ciertas restricciones para reducir el entorno y poder realizar los cálculos en un tiempo razonable. En un movimiento 3-opt, una vez eliminadas las tres aristas hay ocho maneras de conectar los tres caminos resultantes para formar un ciclo. Las figuras siguientes ilustran algunos de los ocho casos. La figura 16 muestra el ciclo inicial en el que se encuentran las aristas (a, b), (c, d) y (e, f) por las que se dividirá éste. La figura 17 utiliza la propia arista (e,f) para reconstruir el ciclo, por lo que, este caso equivale a realizar un movimiento 2-opt sobre las aristas (a,b) y (c,d). Análogamente podemos considerar los otros dos casos en los que se mantiene una de las tres aristas en el ciclo y se realiza un movimiento 2-opt sobre las restantes. Las figuras 18 y 19 muestran un movimiento 3-opt “puro” en el que desaparecen del ciclo las tres aristas seleccionadas.




Figura 16. Ciclo inicial




Figura 17. Movimiento 2-opt




Figura 18. Movimiento 3-opt




Figura 19. Movimiento 3-opt

A diferencia de los movimientos 2-opt, el reconstruir el ciclo una vez eliminadas las tres aristas es muy costoso. Notar que la dirección en el ciclo puede cambiar en todos los caminos menos en el mas largo por lo que hay que realizar varias actualizaciones. Además, el mero hecho de examinar todas las posibilidades representa un esfuerzo computacional enorme (mas de 1 hora en los problemas considerados). Por ello, se consideran únicamente algunos de los movimientos 3-opt. En concreto se define para cada vértice i un conjunto de vértices $N(i)$ de modo que al examinar los movimientos 3-opt asociados a una arista (i,j) , únicamente se consideran aquellos en los que las otras dos aristas tengan al menos uno de los vértices en $N(i)$. Una posibilidad para definir $N(i)$ consiste en considerar los vértices adyacentes a i en el subgrafo candidato.

Algoritmo 3-óptimo restringido

Inicialización

Considerar un ciclo Hamiltoniano inicial

Para cada vértice i definir un conjunto de vértices $N(i)$

move = 1

Mientras (move = 1)

move=0

Etiquetar todos los vértices como no explorados.

Mientras (Queden vértices por explorar)

Seleccionar un vértice i no explorado.

Examinar todos los movimientos 3-opt que eliminen 3 aristas teniendo cada una, al menos un vértice en $N(i)$.

Si alguno de los movimientos examinados reduce la longitud del ciclo, realizar el mejor de todos y hacer move = 1. En otro caso etiquetar i como explorado.

El promedio de las desviaciones al óptimo sobre el conjunto test considerado (TSPLIB) es de 3.8% con esta versión restringida, partiendo de la solución del vecino más próximo, y de 3.9% partiendo de una solución al azar.

3.3 Algoritmo de Lin y Kernighan

Como vimos en la introducción a los métodos de mejora (figura 13), el problema de los algoritmos de búsqueda local es que suelen quedarse atrapados en un óptimo local. Vimos que para alcanzar una solución mejor a partir de un óptimo local habría que comenzar por realizar movimientos que empeoren el valor de la solución, lo que conduciría a un esquema de búsqueda mucho más complejo, al utilizar el algoritmo tanto movimientos de mejora como de no mejora.

El algoritmo de Lin y Kernighan parte de este hecho y propone un movimiento compuesto, en donde cada una de las partes consta de un movimiento que no mejora necesariamente pero el movimiento compuesto sí es de mejora. De esta forma es como si se realizaran varios movimientos simples consecutivos en donde algunos empeoran y otros mejoran el valor de la solución, pero no se pierde el control sobre el proceso de búsqueda ya que el movimiento completo sí que mejora. Además, combina diferentes movimientos simples, lo cual es una estrategia que ha producido muy buenos resultados en los algoritmos de búsqueda local. En concreto la estrategia denominada “cadenas de eyección” se basa en encadenar movimientos y ha dado muy buenos resultados en el contexto de la Búsqueda Tabú.

Se pueden considerar muchas variantes para este algoritmo. En este apartado consideraremos una versión sencilla basada en realizar dos movimientos 2-opt seguidos de un movimiento de inserción. Ilustraremos el procedimiento mediante el ejemplo desarrollado en las figuras siguientes sobre un grafo de 12 vértices. Consideramos el ciclo Hamiltoniano inicial dado por el orden natural de los vértices y lo representamos tal y como aparece en la figura 20.




Figura 20

Paso 1: Realiza un *movimiento 2-opt* reemplazando las aristas (12,1) y (5,6) por (12,5) y (1,6). El resultado se muestra en la figura 21.




Figura 21

Paso 2: Realiza un *movimiento 2-opt* reemplazando las aristas (6,1) y (3,4) por (6,3) y (1,4). Ver figura 22.




Figura 22

Paso 3: Realiza un *movimiento de inserción*, insertando el vértice 9 entre el 1 y el 4 (figura 23).




Figura 23

El algoritmo funciona de igual modo que el 2-óptimo o el 3-óptimo: parte de un ciclo Hamiltoniano inicial y realiza movimientos de mejora hasta alcanzar un óptimo local.

Algoritmo de Lin y Kernighan

Inicialización

Considerar un ciclo Hamiltoniano inicial
move = 1

Mientras (move = 1)

move=0
Etiquetar todos los vértices como no explorados.
Mientras(Queden vértices por explorar)
Seleccionar un vértice i no explorado.
Examinar todos los movimientos (2-opt, 2-opt, inserción) que incluyan la arista de i a su sucesor en el ciclo.
Si alguno de los movimientos examinados reduce la longitud del ciclo, realizar el mejor de todos y hacer move = 1. En otro caso etiquetar i como explorado.

Dado el gran número de combinaciones posibles para escoger los movimientos, es evidente que una implementación eficiente del algoritmo tendrá que restringir el conjunto de movimientos a examinar en cada paso. De entre las numerosas variantes estudiadas para reducir los tiempos de computación del algoritmo y aumentar la eficiencia del proceso, destacamos las dos siguientes:

- Utilizar el subgrafo candidato en el que únicamente figuran las aristas relativas a los 6 vecinos más cercanos para cada vértice. Se admiten movimientos compuestos de hasta 15 movimientos simples todos del tipo 2-opt o inserción. Para el primer movimiento simple únicamente se examinan 3 candidatos.
- El subgrafo candidato está formado por las aristas relativas a los 8 vecinos más cercanos. Se admiten hasta 15 movimientos simples del tipo 2-opt o inserción por cada movimiento completo. En los 3 primeros movimientos simples únicamente se examinan 2 aristas.

Respecto al estudio computacional sobre los ejemplos de la TSPLIB considerados, la desviación del óptimo partiendo de la solución del heurístico del vecino más próximo es de 1.9% para la primera variante y de 1.5% para la segunda.

La siguiente tabla recoge el promedio de las desviaciones del óptimo y tiempos de ejecución de los 4 algoritmos de mejora considerados sobre los 30 ejemplos de la TSPLIB. Todos ellos toman como solución inicial la obtenida con el método del vecino más próximo.

Heurístico	Desviación del Óptimo	T. Ejecución (pr2392)
2-óptimo	8.3 %	0.25
3-óptimo	3.8 %	85.1
Lin y Kernighan 1	1.9 %	27.7
Lin y Kernighan 2	1.5 %	74.3

Respecto a los tiempos de ejecución, podemos ver cómo el pasar de una exploración 2-opt a 3-opt aumenta considerablemente el tiempo, incluso en la versión restringida planteada. También es de señalar cómo aumenta el tiempo, en casi un factor de 3, de una versión a otra del algoritmo de Lin y Kernighan, mientras que el porcentaje de desviación respecto del óptimo únicamente gana un 0.4 %.

A la vista de los resultados, parece mas interesante utilizar movimientos compuestos, que permiten controlar movimientos simples de no mejora, que utilizar movimientos k-óptimos con valores altos de k que, por su complicación, consumen mucho tiempo y, sin embargo, no llegan a tan buenos resultados.

4. Métodos Combinados

En los apartados anteriores hemos visto los métodos constructivos que obtienen una solución del problema y los métodos de mejora que, a partir de una solución inicial, tratan de obtener nuevas soluciones con mejor valor. Es evidente que ambos métodos pueden combinarse, tomando los segundos como solución inicial la obtenida con los primeros. En este apartado estudiaremos algunas variantes y mejoras sobre tal esquema.

Como hemos visto, una de las limitaciones más importantes de los métodos heurísticos es la denominada miopía provocada por seleccionar, en cada paso, la mejor opción. Resulta muy ilustrativo que en los métodos de inserción, se obtengan mejores resultados al elegir al azar el vértice a insertar, que al tomar el elemento más cercano (11.1% frente a 20% de promedio de desviación del óptimo). Sin embargo, es evidente que el tomar una opción al azar como norma puede conducirnos a cualquier resultado, por lo que parece más adecuado recurrir a algún procedimiento sistemático que compendie la evaluación con el azar. Veamos dos de los más utilizados.

4.1 Procedimientos Aleatorizados

Una modificación en el algoritmo de construcción consiste en sustituir una elección *greedy* por una elección al azar de entre un conjunto de buenos candidatos. Así, en cada paso del procedimiento, se evalúan todos los elementos que pueden ser añadidos y se selecciona un subconjunto con los mejores. La elección se realiza al azar sobre ese subconjunto de buenos candidatos.

Existen varias maneras de establecer el subconjunto de mejores candidatos. En un problema de maximización, en donde cuanto mayor es la evaluación de una opción más “atractiva” resulta, podemos destacar:

- Establecer un número fijo k para el subconjunto de mejores candidatos e incluir los k mejores.
- Establecer un valor umbral e e incluir en el conjunto todos los elementos cuya evaluación esté por encima de dicho valor. Incluir siempre el mejor de todos.
- Establecer un porcentaje respecto del mejor, e e incluir en el subconjunto todos aquellos elementos cuya evaluación difiere, de la del mejor en porcentaje, en una cantidad menor o igual que la establecida.

En todos los casos la elección final se realiza al azar de entre los preseleccionados.

Una estrategia alternativa a la anterior consiste en considerar las evaluaciones como pesos y utilizar un método probabilístico para seleccionar una opción. Así, si v_1, v_2, \dots, v_k son los posibles elementos a añadir en un paso del algoritmo, se calculan sus evaluaciones e_1, e_2, \dots, e_k , y se les asigna un intervalo del siguiente modo:

Elemento	Evaluación	Intervalo
v_1	e_1	$[0, e_1[$
v_2	e_2	$[e_1, e_1 + e_2[$
\dots	\dots	\dots
v_k	e_k	$\left[\sum_{i=1}^{k-1} e_i, \sum_{i=1}^k e_i \right]$

Se genera un número a al azar entre 0 y $\sum_{i=1}^k e_i$, y se selecciona el elemento correspondiente al intervalo que contiene a a .

Al algoritmo constructivo modificado, tanto con la opción primera como con la segunda, lo llamaremos **algoritmo constructivo aleatorizado**. Este algoritmo puede que produzca una solución de peor calidad que la del algoritmo original. Sin embargo, dado que el proceso no es completamente determinista, cada vez que lo realicemos sobre un mismo ejemplo obtendremos resultados diferentes. Esto permite definir un proceso iterativo consistente en ejecutar un número prefijado de veces (*MAX_ITER*) el algoritmo y quedarnos con la mejor de las soluciones obtenidas. Obviamente, cada una de dichas soluciones puede mejorarse con un algoritmo de búsqueda local. El siguiente procedimiento incorpora el algoritmo de mejora a dicho esquema.

Algoritmo combinado aleatorizado*Inicialización*

Obtener una solución con el algoritmo constructivo aleatorizado.
Sea c^ el coste de dicha solución.*
Hacer $i = 0$

Mientras ($i < MAX_ITER$)

Obtener una solución $x(i)$ con el algoritmo constructivo aleatorizado.
Aplicar el algoritmo de búsqueda local a $x(i)$.
Sea $x^(i)$ la solución obtenida y $S^*(i)$ su valor.*
Si ($S^(i)$ mejora a c^*)*
 Hacer $c^ = S^*(i)$ y guardar la solución actual*
 $i = i + 1$

En cada iteración el algoritmo construye una solución (fase 1) y después trata de mejorarla (fase 2). Así, en la iteración i , el algoritmo construye la solución $x(i)$ con valor $S(i)$ y posteriormente la mejora obteniendo $x^*(i)$ con valor $S^*(i)$. Notar que $x^*(i)$ puede ser igual a $x(i)$ si el algoritmo de la segunda fase no encuentra ningún movimiento que mejore la solución.

Después de un determinado número de iteraciones es posible estimar el porcentaje de mejora obtenido por el algoritmo de la fase 2 y utilizar esta información para aumentar la eficiencia del procedimiento. En concreto, al construir una solución se examina su valor y se puede considerar que la fase 2 la mejoraría en un porcentaje similar al observado en promedio. Si el valor resultante queda alejado del valor de la mejor solución encontrada hasta el momento, podemos descartar la solución actual y no realizar la fase 2 del algoritmo, con el consiguiente ahorro computacional.

Dadas las numerosas variantes posibles sobre el esquema propuesto, no las incluiremos en la comparativa realizada sobre los 30 ejemplos de la TSPLIB. Únicamente citar que en general los resultados son de mejor calidad que los obtenidos por el heurístico de Lin y Kernighan (alrededor de un 0.5 %) aunque a expensas de emplear tiempos de computación bastante mayores (del orden de algunos minutos).

Dado el interés por resolver problemas enteros en general, y en particular el TSP, se han propuesto numerosas mejoras y nuevas estrategias sobre el esquema anterior. Una de las más utilizadas es la denominada técnica de Multi-Arranque que abordamos en la próxima sección.

4.2 Métodos Multi - Arranque

Los métodos Multi-Start (también llamados Re-Start) generalizan el esquema anterior. Tienen dos fases: la primera en la que se genera una solución y la segunda en la que la solución es típicamente, pero no necesariamente, mejorada. Cada iteración global produce una solución, usualmente un óptimo local, y la mejor de todas es la salida del algoritmo.

Algoritmo Multi-Arranque*Mientras (Condición de parada)***Fase de Generación**

Construir una solución.

Fase de Búsqueda

Aplicar un método de búsqueda para mejorar la solución construida

Actualización

Si la solución obtenida mejora a la mejor almacenada, actualizarla.

Dada su sencillez de aplicación, estos métodos han sido muy utilizados para resolver gran cantidad de problemas. En el contexto de la programación no lineal sin restricciones, podemos encontrar numerosos trabajos tanto teóricos como aplicados. Rinnoy Kan y Timmer (1989) estudian la generación de soluciones aleatorias (métodos Monte Carlo) y condiciones de convergencia. Las primeras aplicaciones en el ámbito de la optimización combinatoria consistían en métodos sencillos de construcción, completa o parcialmente aleatorios, y su posterior mejora con un método de búsqueda local. Sin embargo el mismo esquema permite sofisticar el

procedimiento basándolo en unas construcciones y/o mejoras mas complejas. Numerosas referencias y aplicaciones se pueden encontrar en Martí (2000).

Uno de los artículos que contiene las ideas en que se basa el método Tabu Search (Glover, 1977) también incluye aplicaciones de estas ideas para los métodos de multi-start. Básicamente se trata de almacenar la información relativa a soluciones ya generadas y utilizarla para la construcción de nuevas soluciones. Las estructuras de memoria reciente y frecuente se introducen en este contexto. Diferentes aplicaciones se pueden encontrar en Rochat y Taillard (1995) y Lokketangen y Glover (1996).

Utilizando como procedimiento de mejora un algoritmo genético, Ulder y otros (1990) proponen un método para obtener buenas soluciones al problema del agente viajero. Los autores muestran cómo el uso de las técnicas de re-starting aumenta la eficiencia del algoritmo comparándolo con otras versiones de heurísticos genéticos sin re-starting.

Un problema abierto actualmente para diseñar un buen procedimiento de búsqueda basada en multi- arranque es si es preferible implementar un procedimiento de mejora sencillo que permita realizar un gran número de iteraciones globales o, alternativamente, aplicar una rutina más compleja que mejore significativamente unas pocas soluciones generadas. Un procedimiento sencillo depende fuertemente de la solución inicial pero un método más elaborado consume mucho más tiempo de computación y, por tanto, puede ser aplicado pocas veces, reduciendo el muestreo del espacio de soluciones.

Una de las variantes más populares de estos métodos se denomina GRASP (Feo y Resende, 1995) y está obteniendo resultados excelentes en la resolución de numerosos problemas combinatorios. La próxima sección describe en detalle estos métodos.

Bibliografía

- Campos V., Laguna M. y Martí R. (1999), "Scatter Search for the Linear Ordering Problem", New Ideas in Optimisation, D. Corne, M. Dorigo and F. Glover (Eds.), McGraw-Hill. 331-341.
- Campos V., Laguna M. y Martí R. (2001) "Context-Independent Scatter and Tabu Search for Permutation Problems", Technical report TR03-2001, Departamento de Estadística e I.O., Universidad de Valencia.
- Campos, V., F. Glover, M. Laguna and R. Martí (1999) "An Experimental Evaluation of a Scatter Search for the Linear Ordering Problem to appear in Journal of Global Optimization.
- Corberán A., E. Fernández, M. Laguna and R. Martí (2000), "Heuristic Solutions to the Problem of Routing School Buses with Multiple Objectives", Technical report TR08-2000, Departamento de Estadística e I.O., Universidad de Valencia.
- Davis, L. (1996), Handbook of Genetic Algorithms, International Thomson Computer Press, Londres.
- Díaz, A., Glover, F., Ghaziri, H.M., Gonzalez, J.L., Laguna, M., Moscato, P. y Tseng, F.T. (1996). Optimización Heurística y Redes Neuronales, Paraninfo, Madrid.
- Feo, T. and Resende, M.G.C. (1989), A probabilistic heuristic for a computational difficult set covering problems, *Operations research letters*, 8, 67-71.
- Feo, T. and Resende, M.G.C. (1995), "Greedy Randomized Adaptive Search Procedures", *Journal of Global Optimization*, 2, 1-27.
- Festa, P. and Resende, M.G.C. (2001), "GRASP: An Annotated Bibliography", *AT&T Labs Research Tech. Report*.
- Fisher, M.L. (1980), "Worst-Case Analysis of Heuristic Algorithms", *Management Science*, 26, pág. 1-17.
- Glover, F. (1977) "Heuristics for Integer Programming Using Surrogate Constraints," *Decision Sciences*, Vol. 8, pp. 156-166.
- Glover, F. (1986) "Future Paths for Integer Programming and Links to Artificial Intelligence", *Computers and Operations Research*, 13, 533.
- Glover, F. (1989), "Tabu Search: Part I", *ORSA Journal on Computing*, 1, 190.
- Glover, F. (1990), "Tabu Search: Part II", *ORSA Journal on Computing*, 1, 4.
- Glover, F. (1998) "A Template for Scatter Search and Path Relinking," in *Artificial Evolution, Lecture Notes in Computer Science* 1363, J.-K. Hao, E. Lutton, E. Ronald, M. Schoenauer and D. Snyers (Eds.), Springer-Verlag, pp. 13-54.
- Glover, F., M. Laguna and R. Martí (1999) "Scatter Search," to appear in *Theory and Applications of Evolutionary Computation: Recent Trends*, A. Ghosh and S. Tsutsui (Eds.), Springer-Verlag.
- Glover, F., M. Laguna and R. Martí (2000), "Fundamentals of Scatter Search and Path Relinking", *Control and Cybernetics*, 29 (3), 653-684.
- Glover, F., M. Laguna, E. Taillard and D. de Werra (1993), "A user's guide to tabu search", *Annals of Operations Research*, 4, 3-28.
- Glover, F. and Laguna, M. (1997), *Tabu Search*, Ed. Kluwer, London.
- Holland, J.H. (1992), Genetic Algorithms, *Scientific American*, 267, 66.
- Johnson, D.S., Aragon, C.R., McGeoch, L.A. and Schevon, C. (1989), Optimization by Simulated Annealing: An experimental evaluation; Part I, Graph Partitioning, *Operations Research* 37.
- Johnson, D.S., Aragon, C.R., McGeoch, L.A. and Schevon, C. (1991), Optimization by Simulated Annealing: An experimental evaluation; Part II, Graph Coloring and Number Partitioning, *Operations Research* 39.
- Jünger, M., Reinelt, G. y Rinaldi, G. (1995), "The Traveling Salesman Problem", En: Ball, M.O., Magnanti, T.L., Monma, C.L. y Nemhauser, G.L. (eds.), *Handbook in Operations Research and Management Science*, Vol. 7, Network Models, pág 225--330. North-Holland, Amsterdam.
- Kirkpatrick, S., Gelatt, C.D. and Vecchi, P.M. (1983), Optimization by simulated annealing, *Science*, 220, 671-680

- Laguna M. and Martí R. (2000) “ Experimental Testing of Advanced Scatter Search Designs for Global Optimization of Multimodal Functions”. Technical report TR11-2000, Departamento de Estadística e I.O., Universidad de Valencia.
- Laguna M. and Martí R. (1999), “GRASP and Path relinking for two layer straight-line crossing minimization”, *INFORMS Journal on Computing*, 11(1), 44-52.
- Laguna M. and Martí R. (2002), “The OptQuest Callable Library” Optimization Software Class Libraries, Voss and Woodruff (Eds.), 193-218, Kluwer.
- Laporte, G. (1992), “The Travelling Salesman Problem: An Overview of Exact and Approximate Algorithms”, *European Journal of Operational Research*, 59, pág. 231--247.
- Lawler, E.L., Lenstra, J.K., Rinnooy Kan, A.H.G. y Shmoys, D.B. (eds.) (1985), *The Traveling Salesman Problem. A Guided Tour to Combinatorial Optimization*, John Wiley and Sons, Chichester.
- Lin, S. y Kernighan, B.W. (1973), “An Effective Heuristic Algorithm for the Traveling Salesman Problem”, *Operations Research*, 21, pág. 498--516.
- Locketangen, A. and Glover, F. (1996) “Probabilistic move selection in tabu search for 0/1 mixed integer programming problems” *Meta-Heuristics: Theory and Practice*, Kluwer, pp. 467-488.
- Martí, R. (2000), “MultiStart Methods” to appear in *Handbook on MetaHeuristics*, Kluwer.
- Michalewicz, Z. (1996), *Genetic Algorithms + Data Structures = Evolution Programs*, tercera edición, Springer Verlag.
- Osman, I.H. and Kelly, J.P. (eds.) (1996), *Meta-Heuristics: Theory and Applications*, Kluwer Academic, Boston.
- Padberg, M.W. y Hong, S. (1980), “On the Symmetric Travelling Salesman Problem: A Computational Study”, *Mathematical Programming Study*, 12, pág. 78-107.
- Reeves, C.R. (1995), *Modern Heuristic Techniques for Combinatorial Problems*, McGraw-Hill, UK.
- Rinnooy Kan, A.H.G. and Timmer, G.T. (1989) “Global Optimization” *Handbooks in operations research and management science*, Vol. 1, Ed. Rinnooy Kan and Todd, North Holland, pp. 631-662.
- Rochat and Taillard (1995) “Probabilistic diversification and intensification in local search for vehicle routing” *Journal of heuristics*, Vol. 1, 1, pp 147-167.
- Silver, E.A., Vidal, R.V. y De Werra, D. (1980), “A Tutorial on Heuristic Methods”, *European Journal of Operational Research*, 5, pág. 153—162.
- Ugray Z., Lasdon, J. Plummer, F. Glover, J. Kelly and R. Martí (2001) “A Multistart Scatter Search Heuristic for Smooth NLP and MINLP Problems”, Technical report, University of Texas at Austin.
- Ulder, N.L.J., Aarts, E.H.L., Bandelt, H.J., Van Laarhoven, P.J.M. and Pesch, E. (1990) “Genetic Local Search algorithms for the traveling salesman problem”, *Parallel problem solving from nature*, Eds. Schwefel and Männer, Springer Verlag, pp. 109-116.
- Whitley D. (1993), *A genetic Algorithm Tutorial*, Tech. Report CS-93-103, Colorado State University.

PROCEDIMIENTOS METAHEURÍSTICOS

Índice de textos adjuntos

Introducción

R. Martí (2003), Procedimientos Metaheurísticos en Optimización Combinatoria, *Matemàtiques* 1(1), 3-62

GRASP

M.G.C. Resende, J.L. González Velarde (2003). GRASP: Procedimientos de Búsqueda Miopes Aleatorizados y Adaptativos. *Revista Iberoamericana de Inteligencia Artificial* 19, 61-76.

Búsqueda Tabú

F. Glover, B. Melián (2003). Búsqueda Tabú. *Revista Iberoamericana de Inteligencia Artificial* 19 29-48.

Enfriamiento Simulado

K.A. Dowsland, B.A. Díaz (2003). Diseño de Heurísticas y Fundamentos del Recocido Simulado. *Revista Iberoamericana de Inteligencia Artificial* 19, 93-102.

Métodos Evolutivos

E. Alba, M. Laguna y R. Martí (2003), Métodos evolutivos en problemas de optimización, *Ingeniería UC* 10 (3), 80-89.

R. Martí, M. Laguna (2003). Scatter Search: Diseño Básico y Estrategias Avanzadas. *Revista Iberoamericana de Inteligencia Artificial* 19, 123-130.

P. Moscato, C. Cotta (2003). Una Introducción a los Algoritmos Meméticos. *Revista Iberoamericana de Inteligencia Artificial* 19, 131-148.

Búsqueda de Entorno Variable

P. Hansen, N. Mladenovic, J.A. Moreno Pérez (2003). Búsqueda de Entorno Variable. *Revista Iberoamericana de Inteligencia Artificial* 19, 77-92.

Colonias de Hormigas

S. Alonso, O. Cordón, I. Fernández de Viana y F. Herrera (2003), La Metaheurística de Optimización Basada en Colonias de Hormigas: Modelos y Nuevos Enfoques, Departamento de Ciencias de la Computación e Inteligencia Artificial, Technical Report.